

GOAI世界人工智能开源大赛

刃知

基于 AgentTeams 的刀具磨损监测算法辅助平台

作品简介

● 项目名称

面向机械科研人员的算法实验助手

刃知 / AgentTeams

● 问题与场景

多通道模型选择与试错成本高

实验上下文难复用

● 核心解决方案

六 Agent + 十 Skill + 人工审批

一条可恢复闭环

● 创新点与差异化

LLM 判断, 确定性服务计算

防泄漏 + 可审计

● 开放 / 复用价值

Agent / Skill / API 契约可迁移

代码与接口开放

● 当前进展

PHM2010 C1 全链路真实跑通

F1 0.9375 / 28 Evidence

目录

1 场景与价值

2 方案总览

3 多 Agent 协同设计

4 Skill 工程体系

5 工程验证与安全

6 开放 / 开源计划

7 落地进展与证据

8 团队与未来

对应评分维度

场景价值与行业可复制性


25%

第一章

场景与价值

让实验判断可复用，而不是反复试模型

用户在网页锁定数据、标签、滑窗、抽样和训练目标；系统先完成数据体检与无泄漏切分，再进入候选生成。



真实界面 · 新建实验 / 数据治理

第二章

方案总览

一次实验沿七阶段推进，任何一步都能恢复

主控拆解任务 → Agent 按职责执行 → ExperimentState / PipelineSpec / EvidenceRef 传递上下文 → validation 验证 → 失败重试、换方案或停止 → Trace 归档。

ToolWear Console

PHM2010 · 四阶段磨损分类

运行状态

API

正常

SQLite

正常

LLM

已配置

CUDA

可用

Agent Runtime

可用

Agent Teams

已验证

Higress

已验证

当前实验

刀研智协初赛演示实验 · DRA

+ 新建

刷新

六个业务 Agent

01 ExperimentManagerAgent

02 DataStewardAgent

03 AlgorithmArchitectAgent

04 CodeTrainingEngineerAgent

ACTIVE EXPERIMENT

Deploy

当前状态

待准备

Revision 1 · 事件 29

experiment-def463e61abd4da1b5f4c84a58878265 · trace-fb0fbc1f707642faad890d6796bd963d

01 实验定义

02 数据准备

03 候选方案

04 方案校验

05 模型训练

06 结果评估

07 决策归档

数据准备

候选与参数

真实训练

评估与决策

日志与证据

Agent 协作

数据与标签基线

切分以 cut 为最小分组单位。同一 CSV 产生的窗口只会进入一个数据集，测试集不会参与候选选择、调参或停止决策。

数据集 / 刀具

窗口

重叠率

训练抽样

phm2010 / C1

4096 点

50%

20%

输入通道

VB 标签策略

切分策略

force_x、force_y、force_z、vibration_x、vibration_y、vibration_z、acoustic_emission_rms

max · 90.0 / 130.0 / 160.0 μm

group_by_cut · 60% / 20% / 20%

准备证据

待执行 · 数据体检

待执行 · 标签生成

待执行 · 切分与泄漏审计

核对 C1 文件数、信号列数、磨损标签及清单哈希。

三刃 VB 聚合后按阈值生成初期、正常、剧烈、失效四阶段。

先按 cut 切分，再在训练集内部按阶段比例抽取小样本窗口。

执行尚未完成的数据准备

7

对应评分维度

多 Agent 协同与自主闭环能力

25%

第三章

多 Agent 协同设计

六个 Agent 分工，协作全程留痕

主控拆解任务；Worker 以 experiment、revision、trace 和 EvidenceRef 交接上下文。Registry 输入缺失会被拒绝，补齐后有限重试。

ToolWear Console

PHM2010 - 四阶段编排分类

运行状态

API

正常

SQLite

正常

LLM

已配置

CUDA

可用

Agent Runtime

可用

AgentTeams

已验证

Higress

已验证

当前实验

刀研智协初赛演示实验 • COM

+ 新建

刷新

六个业务 Agent

01 ExperimentManagerAgent

02 DataStewardAgent

03 AlgorithmArchitectAgent

04 CodeTrainingEngineerAgent

刀研智协初赛演示实验

小样本闭环完成

Revision 1: 事件 37

experiment=def063e61abb4da1b5f4c84a58878265 · trace=f3bfbcf1f707642faad898d67940d4963d

01 实验定义

02 数据准备

03 候选方案

04 方案校验

05 模型训练

06 结果评估

07 决策归档

数据准备 · 候选与参数 · 真实训练 · 评估与决策 · 日志与证据 · Agent 协作

固定 Agent

6

调用记录

7

已完成

7

失败

1

ExperimentManagerAgent · 实验主控 Agent · 成功

DataStewardAgent · 数据治理 Agent · 成功

AlgorithmArchitectAgent · 算法方案 Agent · 等待人工

CodeTrainingEngineerAgent · 代码训练 Agent · 成功

EvaluationGovernorAgent · 评估治理 Agent · 等待人工

ReportMemoryCuratorAgent · 报告记忆 Agent · 成功

调用时间线

时间	Agent	任务	状态	模型	耗时(ms)	Token	Evidence
2026-08-16T03:12:38.579190Z	AlgorithmArchitectAgent	review-candidates	等待人工	qwen3.7-flash-2026-07-15	32094	4543	agent-task-6d52ca5fd6fa7d1e51fecc1-call
2026-08-16T03:11:03.513621Z	ReportMemoryCuratorAgent	curate-report-memory	成功	qwen3.7-flash-2026-07-15	43953	8342	agent-task-b678ee77c283c545e0182cfd-ca
2026-08-16T03:10:29.687881Z	EvaluationGovernorAgent	review-validation	等待人工	qwen3.7-flash-2026-07-15	33781	5727	agent-task-4aede2ced4ab26703483fcb-ba
2026-08-16T03:10:15.321860Z	CodeTrainingEngineerAgent	review-training-run	成功	qwen3.7-flash-2026-07-15	14328	2498	agent-task-f72d46396722839b0ffe150f-call
2026-08-16T03:09:47.776755Z	AlgorithmArchitectAgent	review-candidates	失败	qwen3.7-flash-2026-07-15	27500	4238	agent-task-e154b0d749d061601cf5e71a-ca

Team: ToolWear_agent

工具可用性结论

工具	状态	备注
projectflow(create_project)	✓ 可用	ok:true
projectflow(plan_dag)	✓ 可用	ok:true
projectflow(ready_nodes)	✓ 可用	ok:true
taskflow(delegate_task)	✓ 可用	ok:true, synced:true, notification.sent:true (所有5次)
taskflow(check_task)	✓ 可用	ok:true, effective:true (所有5次验证)
taskflow(ack_task)	✓ 可用	Worker 侧报告全部 ok:true
taskflow(submit_task)	✓ 可用	Worker 侧报告全部 ok:true, synced:true, verified:true
共享存储 (MinIO mc mirror)	✓ 已修复	Task 5 check_task 拉取成功

未执行操作确认

全部 5 项任务均为只读 inspect 模式。无任何写业务数据、训练或删除操作被触发。

项目 DAG 节点已全部完成 (ready_nodes 返回空列表)。

🔍 toolwear-data-steward — 收到 Task 1 恢复任务完成通知。check_task 已验证: status = submitted, effective = true, submit_time = 09:55:25, 结果与首次提交一致。

最终确认

项目 tw-six-agent-final-20260815-094836 全部 5 个 DAG 节点已完成, ready_nodes 返回空列表。此前已在最终汇总报告中记录五项任务的终态详情。此恢复确认不改变任何已有结论。

toolwear-experiment-manager

🔍 toolwear-data-steward 心跳检查发现任务 toolwear-toolcheck-20260815-093500-1 (工具可用性验证) 未运行。请继续执行该任务, 参考 shared/tasks/toolwear-toolcheck-20260815-093500-1/spec.md 和已有 workspace/, 完成后发布 result.md 或说明阻塞。

🔍 toolwear-report-memory-curator 心跳检查发现任务 tw-e2e-20260815-093900-5 (ReportMemoryCurator: 证据制品 inspect) 未运行。请继续执行该任务, 参考 shared/tasks/tw-e2e-20260815-093900-5/spec.md 和已有 workspace/, 完成后发布 result.md 或说明阻塞。

对应评分维度

Skill 工程体系与生态复用

25%

第四章

Skill 工程体系

十个 Skill 把建议变成有契约的可执行动作

每个 Skill 都有 Owner、SKILL.md、client.py、输入/输出 JSON Schema、权限白名单、失败处理和 Evidence 审计；下图来自项目真实 Manifest 与脱敏调用记录。

真实工程资产 • docs/skill-manifest.md + Worker Skill Package

十个 Skill 具备可执行契约，不是 Prompt 中的角色描述

每个 Skill 均包含 SKILL.md、client.py、输入/输出 JSON Schema，并受 Agent 白名单、Bearer Token、幂等键和 Evidence 审计约束。

Skill	Owner	主要输出	失败与安全边界
toolwear-data-profile	DataSteward	DataProfile + EvidenceRef	数据缺失时阻断
toolwear-stage-label	DataSteward	LabelRecord[]	阈值非法时拒绝
toolwear-window-split	DataSteward	SplitManifest + LeakageAudit	跨 cut 泄漏时阻断
toolwear-pipeline-recommend	AlgorithmArchitect	PipelineSpec[]	Schema/Registry 校验
toolwear-human-selection	ExperimentManager	ApprovalRecord	非法状态拒绝
toolwear-mini-train	CodeTrainingEngineer	RunBundle + Metrics	OOM/超时保留失败证据
toolwear-visualization	EvaluationGovernor	FigureRef[]	单图失败可降级
toolwear-diagnosis	EvaluationGovernor	DiagnosisReport	测试集污染时阻断
toolwear-decision	EvaluationGovernor	DecisionProposal	训练动作需人工审批
toolwear-report-trace	ReportMemoryCurator	Report + MemoryCase	证据缺失只列缺口

来源：项目 Skill Manifest、Agent Identity Catalog、脱敏 AgentTeams E2E Manifest

一次真实调用的共享上下文

experiment	p0-diagnosis-smoke-20260815
trace	trace-7afd25bfa6484063b84dc966dc6ea407
verification	agt-e2e-final-20260815174832
framework	AgentTeams v1.2.2

调用链与验证

AgentTeams 分派
→ Owner 权限校验
→ Skill 输入 Schema
→ FastAPI Tool API
→ 输出 Schema + EvidenceRef
→ SQLite / Trace 归档

可迁移边界

业务 Schema 与 transport 分离；新增数据适配器或模型模块时只扩展 Registry，后续可增加 MCP adapter，无需重写训练与审计链。

对应评分维度

工程落地与安全可审计

20%

第五章

可行性、异常分支与安全边界均可验证

一次真实 Demo 已从候选生成跑到专家诊断

PHM2010 C1: 315 cut, 按 cut 隔离 60/20/20; 训练集内分层抽取 20%, validation Macro-F1 0.9375, final test 未使用。

ToolWear Console

PHM2010 故障诊断分类

运行状态

API

正常

SQLite

正常

LLM

已配置

CUDA

可用

Agent Runtime

可用

Agent Teams

已验证

Hgress

已验证

当前实验

刀研智协初赛演示实验 • WAI

+ 新建

切换

六个业务 Agent

01 ExperimentManagerAgent

02 DataStewardAgent

03 AlgorithmArchitectAgent

04 CodeTrainingEngineAgent

刀研智协初赛演示实验

等待方案选择

Revision 1 事件 22

01 实验定义

02 数据准备

03 候选方案

04 方案校验

05 模型训练

06 结果评估

07 决策归档

数据准备 候选与参数 真实训练 评估与决策 日志与证据 Agent 协作

候选方案与人工确认

LLM 负责结合实验背景提出 2-3 个候选; Registry 负责过滤不存在、未实现或不兼容的候选。只有用户确认后此方案才会进入训练。

训练法架构 Agent 的要求

使用 PHM2010 C1 七通渠制编号完成刀具磨损的阶段分类。先由 Agent 生成可行候选, 经人工审核后开展小规模小样本训练, 再依据 validation 指标完成诊断、决策与证据归档。

选择 LLM 生成候选

Provider

qwen

Model

qwen3.7-flash-2026-0...

候选数

3

使用证据

否

选择一个候选方案

Statistical Features + Random Forest Baseline

Multi-Channel ID Chit with Weighted Loss

Extra Trees with Early Fusion

预计成本

低

可真实训练

是

继续训练

重置训练窗口 • 时域统计特征 + RandomForest 分类器 + xgboost 训练器

利用统计特征提取时域和频域关键指标, 配合随机森林处理小样本数据表现稳健。RobustScaler 对异常值不敏感, 适合工业噪声环境。该方案计算开销较低, 易于快速验证非线性性能且无模型泄露风险。

风险与兼容性

ToolWear Console

PHM2010 故障诊断分类

运行状态

API

正常

SQLite

正常

LLM

已配置

CUDA

可用

Agent Runtime

可用

Agent Teams

已验证

Hgress

已验证

当前实验

刀研智协初赛演示实验 • EVKI

+ 新建

切换

六个业务 Agent

01 ExperimentManagerAgent

02 DataStewardAgent

03 AlgorithmArchitectAgent

04 CodeTrainingEngineAgent

刀研智协初赛演示实验

等待评估

Revision 1 事件 23

01 实验定义

02 数据准备

03 候选方案

04 方案校验

05 模型训练

06 结果评估

07 决策归档

数据准备 候选与参数 真实训练 评估与决策 日志与证据 Agent 协作

真实小样本训练

训练只读取已指定 split 的 train/validation。小样本从训练集内按数据特征分层抽取, 生成的候选、代码训练、参数、指标和日志都会登记为证据。

方案

Statistical Fe...

Batch

64

Epoch

2

学习率

0.001

设备请求

auto

样本上限

不限

运行监控

Run 状态

已完成

Pipeline

statistical_featu...

进度

100%

Epoch

0 / 2

创建时间

08-16 11:04:23

训练完成

结构化训练日志

刷新运行

ToolWear Console

PHM2010 故障诊断分类

运行状态

API

正常

SQLite

正常

LLM

已配置

CUDA

可用

Agent Runtime

可用

Agent Teams

已验证

Hgress

已验证

当前实验

刀研智协初赛演示实验 • DEC

+ 新建

切换

六个业务 Agent

01 ExperimentManagerAgent

02 DataStewardAgent

03 AlgorithmArchitectAgent

04 CodeTrainingEngineAgent

刀研智协初赛演示实验

等待决策

Revision 1 事件 25

01 实验定义

02 数据准备

03 候选方案

04 方案校验

05 模型训练

06 结果评估

07 决策归档

数据准备 候选与参数 真实训练 评估与决策 日志与证据 Agent 协作

评估、诊断与下一步决策

Validation Macro-F1

0.9375

Balanced Accuracy

0.9336

Validation 样本

2016

Train Macro-F1

0.9978

实际设备

cpu

分类报告

阶段

Precision

Recall

F1

Support

初期磨损

0.9655

0.8758

0.9180

320

正常磨损

0.9628

0.8743

0.9085

1088

剧烈磨损

0.8352

0.9663

0.9506

448

失效磨损

0.9074

0.9188

0.9130

160

Validation 混淆矩阵

初期磨损

正常磨损

剧烈磨损

失效磨损

初期磨损

280

40

0

0

正常磨损

10

1060

18

0

剧烈磨损

0

0

433

35

失效磨损

0

1

12

147

运行耗时 4.36 秒; CUDA 未用于本次推理。

Validation t-SNE

ToolWear Console

PHM2010 故障诊断分类

运行状态

API

正常

SQLite

正常

LLM

已配置

CUDA

可用

Agent Runtime

可用

Agent Teams

已验证

Hgress

已验证

当前实验

刀研智协初赛演示实验 • COM

+ 新建

切换

六个业务 Agent

01 ExperimentManagerAgent

02 DataStewardAgent

03 AlgorithmArchitectAgent

04 CodeTrainingEngineAgent

刀研智协初赛演示实验

等待决策

Revision 1 事件 26

01 实验定义

02 数据准备

03 候选方案

04 方案校验

05 模型训练

06 结果评估

07 决策归档

数据准备 候选与参数 真实训练 评估与决策 日志与证据 Agent 协作

可视化训练数据

该图只使用 validation 特征生成, 未读取 final test 数据。

EvaluationGovernorAgent 提醒

Macro F1

0.9375

Balanced Accuracy

0.9336

最弱类别 F1

失效磨损 / 0.9130

建议动作

adjust_parameters

模型在验证集上表现良好 (Macro F1: 0.938), 但存在明显的过拟合迹象 (训练/验证差距约 6%)。主要风险在于类别不平衡导致的失效磨损 类别识别能力相对较弱, 且初期与正常磨损之间存在混淆。鉴于未使用最终测试集, 当前结论仅基于验证集评估。建议进行参数微调以增强泛化能力后再进行最终部署。

真实 LLM 诊断: qwen/qwen3.7-flash-2026-07-15, 耗时 31108 ms。

训练发现

Train-Validation Generalization Gap Detected: Training Macro F1 (0.998) significantly exceeds Validation Macro F1 (0.938), indicating a generalization gap of approximately 0.06. This suggests the model may be overfitting to training data patterns.

Class Support Imbalance Affecting Weakest Class Performance: The support imbalance ratio is 6.8, with 'Normal Wear' having significantly more samples than 'Failure Wear'. The weakest class 'Failure Wear' has the lowest F1 score (0.913) and recall (0.915), likely due to insufficient representation compared to other classes.

对应评分维度

开放 / 开源贡献

5%

第六章

开放 / 开源计划

开放 / 开源计划

公开可复用工程资产，不发布敏感数据。

1. 开放范围

- 六 Agent 身份、Prompt 与协作 schema
- 十个 Skill、Registry、API 契约与测试；提交包含入口、依赖、配置、样例和证据

2. 安全边界

- 不上传 .env、API Key、原始数据、模型权重和本机日志
- 最终测试集默认隔离，第三方依赖明确声明

3. 复用与许可

- README 给出完整流程；Adapter 可迁移到轴承、齿轮等时序任务

第七章 · 当前进展与整体可行性

落地进展与证据

停止决策也有完整证据链

EvaluationGovernorAgent 识别约 0.06 过拟合差距与 6.8 类别不平衡；P0 目标达成后停止额外训练，归档 28 项 Evidence。

ToolWear Console

PHM2010 - 四阶段磨损分类

运行状态

API

正常

SQLite

正常

LLM

已配置

CUDA

可用

Agent Runtime

可用

AgentTeams

已验证

Higress

已验证

当前实验

刀研智协初赛演示实验 • COM

+ 新建

🔄 刷新

六个业务 Agent

01 ExperimentManagerAgent

02 DataStewardAgent

03 AlgorithmArchitectAgent

04 CodeTrainingEngineerAgent

Wear'. The weakest class 'Failure Wear' has the lowest F1 score (0.913) and recall (0.913), likely due to insufficient representation compared to other classes.

High Confusion Between Initial and Normal Wear': The most frequent confusion error involves misclassifying 'Initial Wear' as 'Normal Wear' (40 instances, 12.5% row rate). This indicates that the statistical features used by the Random Forest may not sufficiently distinguish early-stage wear from normal operation states.

Final Test Set Not Used for Evaluation': The evaluation basis is strictly limited to the validation split. No final test results are available or assumed. Conclusions regarding production readiness cannot be fully validated without independent test set performance metrics.

下一 revision 建议

优先级	目标	建议	理由
high	random_forest	Adjust class weights in the Random Forest classifier to penalize misclassification of minority classes ('Failure Wear', 'Initial Wear') more heavily.	Addressing the support imbalance (ratio 6.8) and improving the F1 score of the weakest class will likely reduce the generalization gap and improve robustness on imbalanced real-world data.
medium	sliding_window/statistical_features	Investigate feature discriminability between 'Initial Wear' and 'Normal Wear' classes. Consider adding time-domain or frequency-domain features that capture subtle vibration changes characteristic of early wear.	The high confusion rate (12.5%) between these two classes suggests current statistical features lack sufficient sensitivity to detect initial degradation stages.
medium	training_process	Implement data augmentation techniques for minority classes or use SMOTE during training to balance the dataset distribution before retraining.	Synthetic oversampling can help the model learn better decision boundaries for underrepresented classes, potentially reducing the train-validation gap.

诊断只使用 validation；Final test 未运行，也未进入 LLM 上下文。所有建议都需要用户审批。

已归档决策

stop: 本轮验证 Macro-F1 已达到初赛演示目标；保留过拟合与类别不平衡建议，停止继续消耗训练预算并完成小样本实验归档。

生成 / 恢复 Markdown 实验报告

ToolWear Console

PHM2010 - 四阶段磨损分类

运行状态

API

正常

SQLite

正常

LLM

已配置

CUDA

可用

Agent Runtime

可用

AgentTeams

已验证

Higress

已验证

当前实验

刀研智协初赛演示实验 • COM

+ 新建

🔄 刷新

六个业务 Agent

01 ExperimentManagerAgent

02 DataStewardAgent

03 AlgorithmArchitectAgent

04 CodeTrainingEngineerAgent

刀研智协初赛演示实验

小样本闭环完成

experiment-def603e01abd9da1b5f9c84a58878265 · trace-f3b9fbc1f707042faad89dd6796bd963d

Revision 1: 事件 37

01 实验定义02 数据准备03 候选方案04 方案校验05 模型训练06 结果评估07 决策归档

数据准备 候选与参数 真实训练 评估与决策 日志与证据 Agent 协作

状态事件与证据索引

状态事件

9

证据条目

28

当前 Revision

1

Trace

0d6796bd963d

状态时间线 证据文件 配置快照

序号	时间	状态变化	执行者	原因	证据数
29	08-16 11:00:39	START → DRAFT	human	用户通过 Tool API 创建实验。	0
30	08-16 11:01:43	DRAFT → DATA_VALIDATING	DataStewardAgent	初赛演示：执行可审计的数据准备。	0
31	08-16 11:03:03	DATA_VALIDATING → WAITING_PLAN_SELECTION	AlgorithmArchitectAgent	数据准备证据齐全，进入候选方案选择。	3
32	08-16 11:04:09	WAITING_PLAN_SELECTION → PIPELINE_VALIDATING	ExperimentManagerAgent	用户已批准候选和训练参数，开始组合校验。	0
33	08-16 11:04:09	PIPELINE_VALIDATING → CODE_PREPARING	CodeTrainingEngineerAgent	初赛演示：训练前执行 Registry 与参数校验。	0
34	08-16 11:04:23	CODE_PREPARING → MINI_TRAINING	CodeTrainingEngineerAgent	代码和配置稽核通过，后台训练任务已入队。	0
35	08-16 11:04:51	MINI_TRAINING → EVALUATING	CodeTrainingEngineerAgent	真实训练结束，进入 validation 评估。	0
36	08-16 11:05:40	EVALUATING → DECIDING	EvaluationGovernorAgent	validation 评估完成，进入受预算约束的决策。	3
37	08-16 11:06:19	DECIDING → COMPLETED_MINI	EvaluationGovernorAgent	本轮验证 Macro-F1 已达到初赛演示目标；保留过拟	1

17

第八章 ·

团队与未来

团队与未来

机械研究需求驱动，工程结果以代码、测试和 Evidence 为准。

1. 团队背景

- 机械工程硕士，研究方向：刀具磨损监测
- 负责领域需求、标签策略、实验解释与现场验证

2. 落地计划

- P1：C1 / C4 / C6 跨刀具泛化、域适配与复赛部署
- 3. 产品化路线

P1.5：VB 回归、注意力和多分支融合

- P2：企业数据接入、RAG、观测、回滚、权限治理与 MCP 适配